

Radar PRF BR-101

Pipeline de Engenharia de Dados para Ingestão,
Padronização e Preparação dos Dados da BR-101

Autores: Arthur Wolmer, Bruna Carvalho, Diego Peter, Gislaine Reis,
Guilherme Lopes, Pedro Vilas Bôas

Disciplina: Big Data

Data: Abril de 2026

Sumário

1	Introdução	2
2	Objetivo do Projeto	2
3	Fontes de Dados	2
3.1	PRF — Polícia Rodoviária Federal	3
3.2	DNIT — Departamento Nacional de Infraestrutura de Transportes	3
3.3	IBGE — Instituto Brasileiro de Geografia e Estatística	3
4	Metodologia — Pipeline de Dados	4
4.1	Ingestão / Extração	4
4.2	Transformação	4
4.3	Carregamento	4
4.4	Destino	4
5	Arquitetura da Solução	5
5.1	Diagrama do Pipeline	5
5.2	Arquitetura Parcial Implementada	5
5.3	Fronteira da Silver Atual	6
6	Tecnologias Utilizadas	6
6.1	Stack Tecnológica Atual	6
6.2	Tecnologias Pagas para Refinamento Futuro	6
6.3	Execução do Pipeline	7
7	Equipe e Divisão de Tarefas	7
8	Resultados Parciais	7
8.1	Artefatos Silver Implementados	7
8.2	Checklist de Progresso	8
8.3	Notebooks de EDA	8
9	Conclusões e Trabalhos Futuros	8
9.1	Conclusões	8
9.2	Dificuldades Encontradas	9
9.3	Próximos Passos	9
10	Referências	9

1. Introdução

A BR-101 é uma das rodovias federais mais extensas e importantes do Brasil, percorrendo o litoral desde o Rio Grande do Norte até o Rio Grande do Sul, cruzando 12 unidades da federação. Sua extensão e volume de tráfego a tornam um corredor logístico estratégico, mas também uma via com índices elevados de acidentes de trânsito. O projeto **Radar PRF BR-101** nasce da necessidade de construir uma base analítica robusta para compreender o padrão histórico de ocorrências de acidentes nessa rodovia e, no futuro, alimentar modelos de previsão que possibilitem ações preventivas por parte de órgãos públicos e sociedade civil. Este relatório documenta o estágio atual do projeto: um pipeline de ETL completo para ingestão, padronização e preparação dos dados provenientes da Polícia Rodoviária Federal (PRF), do Departamento Nacional de Infraestrutura de Transportes (DNIT) e do Instituto Brasileiro de Geografia e Estatística (IBGE). O repositório materializa as camadas bronze e silver de um datalake, preparando o terreno para a camada gold e os modelos preditivos.

2. Objetivo do Projeto

O objetivo central do projeto é construir uma base analítica completa e reproduzível para:

- **Apresentação histórica** da ocorrência de acidentes na BR-101, com recorte territorial (município e Região Geográfica Imediata) e temporal (ano, mês, semana).
- **Previsão futura** da ocorrência de acidentes, utilizando modelos de série temporal (como DeepAR) no nível de granularidade RGI $\times$ semana.

Para alcançar esse objetivo, o projeto implementa um pipeline de dados com as seguintes etapas:

1. Ingestão de dados brutos a partir de fontes oficiais (PRF, DNIT, IBGE).
2. Padronização e limpeza dos dados na camada bronze.
3. Transformação e enriquecimento na camada silver, com processamento geoespacial.
4. Cruzamento multi-fonte na futura camada gold, com atribuição territorial e classificação espacial dos acidentes.
5. Preparação de features para modelagem preditiva.

3. Fontes de Dados

O projeto utiliza quatro fontes de dados oficiais e públicas, cada uma com um papel específico no pipeline:

Fonte	Papel	Bronze	Silver
PRF	Fato de acidentes	bronze/prf_accidents	prf_accidents_standardized
DNIT	Geometria BR-101	bronze/dnit_road_network	dnit_br101_corridor
IBGE Mun.	Base territorial	bronze/ibge/municipios	municipalities_preprocessed
IBGE RGI	Regiões geográficas	bronze/ibge/rgi	rgis_preprocessed

Tabela 1: Resumo das fontes de dados e artefatos materializados

3.1 PRF — Polícia Rodoviária Federal

Portal de dados abertos da PRF com tabelas anuais de acidentes por ocorrência. Contém colunas operacionais (UF, município, BR, km) e descritivas (tipo de acidente, condição meteorológica, fase do dia) usadas para construir o histórico de acidentes da BR-101. É a fonte principal de fatos do projeto.

- **Fonte:** <https://www.gov.br/prf/pt-br/aceso-a-informacao/dados-abertos/dados-abertos-da-prf>
- **Período:** 2017 a 2026 (parcial)
- **Formato original:** CSV comprimido (.csv.gz)

3.2 DNIT — Departamento Nacional de Infraestrutura de Transportes

Bases geométricas do Sistema Nacional de Viação (SNV) contendo as geometrias lineares da malha rodoviária federal. Usado para derivar o traçado e o corredor da BR-101 a partir de múltiplos snapshots históricos.

- **Snapshots utilizados:** 201703A, 202107A, 202601A
- **Formato original:** Shapefile (.zip)

O DNIT é a fonte geométrica que permite construir um corredor canônico de 500 metros ao redor da BR-101, unindo os traçados de diferentes anos para capturar realinhamentos históricos.

3.3 IBGE — Instituto Brasileiro de Geografia e Estatística

Malhas territoriais oficiais de 2024, utilizadas em duas dimensões:

- **Municípios:** polígonos oficiais com hierarquia municipal e atributos administrativos para enriquecimento futuro.
- **Regiões Geográficas Imediatas (RGI):** agregações regionais do IBGE que servirão como unidade territorial para a modelagem preditiva.

4. Metodologia — Pipeline de Dados

O pipeline segue a arquitetura medalhão (*bronze* → *silver* → *gold*), padrão amplamente adotado em datalakes. Cada camada tem responsabilidades bem definidas:

- **Bronze:** ingestão *raw* dos dados de origem, com mínima transformação. Garante rastreabilidade e reprocessamento.
- **Silver:** padronização de tipos, limpeza, filtros e enriquecimento geoespacial. Cada fonte é tratada isoladamente.
- **Gold** (futura): cruzamento multi-fonte, atribuição territorial, classificação espacial e preparação de features.

4.1 Ingestão / Extração

A ingestão é realizada por jobs Python que leem os dados das fontes externas e os persistem no formato Parquet na camada bronze:

- `prf_source2bronze`: baixa e consolida as tabelas anuais de acidentes da PRF.
- `dnit_source2bronze`: isola os segmentos da BR-101 a partir dos snapshots do SNV.
- `ibge_municipios_src2bronze`: materializa a malha municipal oficial.
- `ibge_rgi_src2bronze`: materializa a malha de Regiões Geográficas Imediatas.

4.2 Transformação

Na camada silver, cada fonte passa por transformações específicas:

- **PRF:** padronização de tipos, datas, coordenadas e indicadores. Normalização de vírgulas decimais, parsing de timestamps e filtragem por BR declarada.
- **DNIT:** dissolução de geometrias por snapshot, geração de centerlines, buffers de 500 m e união dos corredores para formar o corredor canônico da BR-101.
- **IBGE:** padronização de códigos, nomes, CRS, tipo geométrico e cálculo de área poligonal para municípios e RGIs.

4.3 Carregamento

Todos os artefatos são persistidos em formato Parquet no diretório `data/`, organizado por camada (`bronze/`, `silver/`). O versionamento é feito via DVC, que rastreia os arquivos de dados e permite reprodução completa do pipeline.

4.4 Destino

O destino atual dos dados é o datalake local em formato Parquet. O projeto já possui um adaptador S3 (`S3DatalakeAdapter`) que permitirá migração futura para armazenamento em nuvem sem alteração nos jobs. A camada de consumo (dashboards, relatórios) será implementada na fase gold.

5. Arquitetura da Solução

5.1 Diagrama do Pipeline




Figura 1: Diagrama do pipeline de dados atual

5.2 Arquitetura Parcial Implementada

Os seguintes contratos já estão implementados no repositório:

- BaseETLJob: padroniza o ciclo *extract* → *transform* → *load* → *cleanup*.
- DatalakeAdapter: persiste localmente em `data/` com suporte a backend S3.
- Makefile: expõe a execução local via Docker e a reprodução via DVC.
- `dvc.yaml`: define as etapas bronze e silver do pipeline.

Camada bronze implementada:

- `prf_source2bronze` → `data/bronze/prf_accidents`
- `dnit_source2bronze` → `data/bronze/dnit_road_network`
- `ibge_municipios_src2bronze` → `data/bronze/ibge/municipios`
- `ibge_rgi_src2bronze` → `data/bronze/ibge/rgi`

Camada silver implementada:

- `prf_bronze2silver` → `data/silver/prf_accidents_standardized`
- `dnit_bronze2silver` → `data/silver/dnit_br101_corridor`
- `ibge_bronze2silver` → `data/silver/ibge_territorial_preprocessed/`

5.3 Fronteira da Silver Atual

A silver do projeto para no ponto em que cada fonte ainda pode ser tratada isoladamente. O que fica explicitamente fora da silver atual:

- Interseção DNIT $\times$ IBGE para recortar municípios ou RGIs cruzados pela rodovia.
- Interseção PRF $\times$ DNIT para classificar acidentes dentro/fora do corredor.
- Atribuição PRF $\times$ IBGE para município e RGI.

Essas transformações dependem de mais de uma fonte e devem entrar em jobs posteriores (camada gold).

6. Tecnologias Utilizadas

6.1 Stack Tecnológica Atual

Tecnologia	Papel no Projeto
Python 3.11+	Linguagem principal dos ETLs e utilitários
PySpark	Engine distribuída dos jobs batch
Apache Sedona	Funções geoespaciais no Spark
Parquet	Armazenamento analítico dos datasets
DVC	Versionamento de dados e reprodução do pipeline
Docker Compose	Ambiente local padronizado
Make	Interface operacional dos comandos
uv	Gerenciamento de dependências Python
Pandas / GeoPandas	EDA e especificação via notebooks
Notebooks Jupyter	Análise exploratória e validação

Tabela 2: Tecnologias já utilizadas no projeto

6.2 Tecnologias Pagas para Refinamento Futuro

Tecnologia	Onde Ajuda	Justificativa
Amazon S3	Datalake remoto	Upgrade natural; <code>S3DatalakeAdapter</code> já existe
EMR Serverless	Execução Spark	Elimina cluster fixo; escala para gold
AWS Glue Catalog	Catálogo de tabelas	Faz sentido com mais datasets
Databricks	Plataforma Spark	Governança e observabilidade integradas
QuickSight / Power BI	Consumo gerencial	Viável após camada gold pronta

Tabela 3: Tecnologias pagas candidatas

A escolha mais defensável neste estágio é manter Spark local em Docker com DVC para versionamento e Parquet em `data/` como datalake local. A superfície implementada

ainda está concentrada em bronze e silver, e o custo operacional de subir infraestrutura paga agora é maior do que o benefício.

6.3 Execução do Pipeline

O runtime suportado localmente é o serviço `spark-env` via Docker Compose:

```
# Build e instalao
make docker-build
make install
# Execuo completa
make bronze
make silver
# Reproduo via DVC
make dvc-repro
make dvc-repro-bronze
make dvc-repro-silver
```

7. Equipe e Divisão de Tarefas

A equipe é composta por quatro integrantes, com responsabilidades distribuídas conforme o histórico de contribuições do repositório Git.

Integrante	Papel Principal
Arthur Wolmer	Engenharia de Dados / Liderança técnica
Bruna Carvalho	Infraestrutura e ETL IBGE
Diego Peter	Documentação e Bronze to Silver IBGE
Gislaine Reis	Documentação e ETL source to bronze DNIT
Guilherme Lopes	Documentação
Pedro Vilas Bôas	Documentação

Tabela 4: Distribuição de commits por integrante

8. Resultados Parciais

O pipeline atual materializa com sucesso as camadas bronze e silver para todas as quatro fontes de dados. Os principais artefatos produzidos são:

8.1 Artefatos Silver Implementados

- **prf_accidents_standardized:** acidentes PRF padronizados com tipos corrigidos, datas parseadas, coordenadas normalizadas e filtro por BR-101 declarada.
- **dnit_br101_corridor:** centerlines, corredores (buffer 500 m) e uniões espaciais da BR-101 derivados dos snapshots DNIT 2017, 2021 e 2026.

- **municipalities_preprocessed:** municípios com padronização geométrica, CRS uniformizado e atributos territoriais.
- **rgis_preprocessed:** Regiões Geográficas Imediatas com padronização equivalente.

8.2 Checklist de Progresso

Etapa	Status
Extração (Bronze)	Em progresso
Transformação (Silver)	Em progresso
Armazenamento (Gold)	Pendente
Cruzamento multi-fonte	Pendente
Modelagem preditiva	Pendente

8.3 Notebooks de EDA

Dois notebooks de análise exploratória foram desenvolvidos:

- **eda-p1.ipynb:** exploração inicial da geometria rodoviária e construção do corredor canônico da BR-101.
- **eda-p2.ipynb:** atribuição territorial e análise descritiva dos acidentes.
- **explore_ibge_columns.ipynb:** inspeção das colunas e estrutura dos dados IBGE.

9. Conclusões e Trabalhos Futuros

9.1 Conclusões

O projeto Radar PRF BR-101 atingiu um estágio sólido na construção do pipeline de dados, com as camadas bronze e silver totalmente implementadas e versionadas via DVC. As principais conquistas até o momento incluem:

- **Pipeline reprodutível:** todos os jobs podem ser executados localmente via Docker e Makefile, com rastreabilidade garantida pelo DVC.
- **Processamento geoespacial:** integração do Apache Sedona ao PySpark permite operações geométricas distribuídas em escala.
- **Corredor canônico da BR-101:** construído a partir de múltiplos snapshots DNIT, capturando realinhamentos históricos.
- **Arquitetura extensível:** o DatalakeAdapter já suporta backend S3, facilitando a migração para nuvem.

9.2 Dificuldades Encontradas

- **Dados faltantes:** parcela significativa dos registros PRF não possui coordenadas válidas, exigindo regras de exclusão documentadas.
- **Corredor arbitrário:** o buffer de 500 metros é razoável mas arbitrário, requerendo análise de sensibilidade.
- **Buffer em graus:** a implementação original do notebook realizava buffer em graus em vez de metros, gerando distorções.
- **Realinhamentos:** a união de traçados de diferentes anos pode ser excessivamente permissiva para trechos onde a rodovia mudou significativamente.

9.3 Próximos Passos

O próximo salto arquitetural natural é promover para gold os cruzamentos já definidos no notebook de EDA:

1. Classificar acidentes PRF contra o corredor canônico DNIT.
2. Atribuir acidentes canônicos a município e RGI com as geometrias IBGE.
3. Persistir datasets auditáveis de cobertura, exceções e atribuições.

Após a camada gold, o projeto estará pronto para:

- Treinar pelo menos 2 modelos de machine learning (requisito MLOps) usando ML-Flow para rastreamento.
- Construir o painel de previsão no nível RGI $\times$ semana, possivelmente com modelos como DeepAR.
- Integrar fontes adicionais de dados (clima, calendário, feriados) como features exógenas.
- Migrar o datalake para S3 e o runtime para EMR Serverless, justificando o uso de tecnologias pagas.

10. Referências

Fontes oficiais de dados:

- PRF — Portal de Dados Abertos: <https://www.gov.br/prf/pt-br/aceso-a-informacao/dados-abertos/dados-abertos-da-prf>
- DNIT — Bases Geométricas do SNV: <https://servicos.dnit.gov.br/dnitcloud/index.php/s/oTpPRmYs5AAiNr>
- IBGE — Malha Municipal 2024: https://geoftp.ibge.gov.br/organizacao_do_territorio/malhas_territoriais/malhas_municipais/municipio_2024/Brasil/BR_Municipios_2024.zip

- IBGE — Regiões Geográficas Imediatas 2024: https://geoftp.ibge.gov.br/organizacao_do_territorio/malhas_territoriais/malhas_municipais/municipio_2024/Brasil/BR_RG_Imediatas_2024.zip

Ferramentas e frameworks:

- PySpark: <https://spark.apache.org/docs/latest/api/python/>
- Apache Sedona: <https://sedona.apache.org/>
- DVC: <https://dvc.org/>
- Docker Compose: <https://docs.docker.com/compose/>